Technical Report

Title: The “Merchant Guard” Challenge – Automated Image-Text Consistency Verification

Prepared by 6642078026 Pachara Charuworn

6642025826 Chavakorn Weeraprasertsakul

I. บทสรุปผู้บริหาร (Executive Summary)

รายงานฉบับนี้มีเพื่อพัฒนาระบบ Merchant Guard โดยมีเป้าหมายเพื่อยกระดับ Trust & Safety ในระบบ onboarding ของ merchant โดยตรวจสอบความสอดคล้องเชิงความหมาย (semantic consistency) ระหว่าง ภาพที่ merchant อัปโหลด กับ หมวดหมู่ร้านค้าที่เลือก แบบอัตโนมัติด้วย AI

ปัญหาหลักที่พบคือ merchant บางรายเลือกหมวดหมู่ผิดพลาดหรือเจตนาหลอกระบบ ซึ่งส่งผลกระทบโดยตรงต่อ คุณภาพ marketplace, ความเชื่อมั่นของผู้ใช้ และต้นทุนการตรวจสอบแบบ manual รายงานฉบับนี้นำเสนอ pipeline สำหรับ Image–Text Consistency Checking โดยเปรียบเทียบแนวทาง SOTA สองแบบ และเลือกใช้ Vision–Language Foundation Model (CLIP-based) เป็นแกนหลักของระบบ

ผลลัพธ์ชี้ให้เห็นว่าแนวทาง multimodal embedding ให้สมดุลที่ดีที่สุดระหว่าง performance, scalability และ deployment feasibility พร้อมศักยภาพในการนำไปใช้จริงใน production

II. ที่มาและปัญหาของโครงการ (Problem Statement)

ในกระบวนการ Onboarding ของร้านค้า ปัญหาที่พบคือ:

1. Misclassification: ร้านค้าเลือกหมวดหมู่ไม่ตรงกับสินค้าจริง (เช่น ขายอาหารแต่เลือกหมวด บริการต่างๆ)
2. Fraudulent Content: การอัปโหลดรูปภาพที่ไม่เกี่ยวข้องเพื่อผ่านระบบตรวจสอบ
3. Scalability Issue: การใช้แรงงานคนตรวจสอบ (Manual Verification) ไม่สามารถรองรับจำนวนร้านค้าที่เพิ่มขึ้นอย่างรวดเร็วได้

เป้าหมายคือการสร้าง Pipeline ที่สามารถประเมิน Semantic Match ระหว่างภาพและข้อความได้อย่างแม่นยำและเป็นอัตโนมัติ

III. รายละเอียดและโครงสร้างของข้อมูล (Data Description)

3.1 Dataset Overview

ข้อมูลที่ใช้ในการศึกษานี้มาจากกระบวนการ onboarding ของ merchant จริง โดยมีรายละเอียดดังนี้:

- จำนวนร้านค้าทั้งหมด: 80 ร้านค้า
- ร้านค้าที่สามารถเปิดดูรูปภาพได้จริง: 76 ร้านค้า
- จำนวนรูปภาพทั้งหมด: 386 รูป
- เฉลี่ยจำนวนภาพต่อร้าน: ~5 รูป / ร้าน

ข้อสังเกตเชิงคุณภาพ:

- การมีหลายภาพต่อร้านสะท้อนลักษณะข้อมูลแบบ multi-instance per entity
- ภาพภายในร้านเดียวกันอาจมี semantic variation สูง (เช่น สินค้า, หน้าร้าน, โลโก้)

3.2 Category และ Subcategory Structure

ระบบกำหนด Merchant Category ทั้งหมด 6 หมวดหลัก ได้แก่:

1. ช้อปปิ้ง
2. อาหารและเครื่องดื่ม
3. บริการต่างๆ
4. สุขภาพและความงาม
5. ท่องเที่ยว
6. บันเทิง

โดยมี Subcategory ที่มีความละเอียดสูงและไม่สมดุล (imbalanced) ตาม mapping ที่กำหนด ซึ่งมีผลโดยตรงต่อ:

- Semantic ambiguity ของภาพ
- ความยากของ task ในระดับ subcategory

ตัวอย่างเชิงวิเคราะห์:

- หมวด ช้อปปิ้ง มี subcategory มากกว่า 20 กลุ่ม ⟶ intra-class variance สูง
- หมวด ท่องเที่ยว มีเพียง subcategory เดียว ⟶ semantic density ต่ำแต่ชัดเจน

3.3 Label Distribution และ Class Imbalance

จากการตรวจสอบความถูกต้องของข้อมูล:

- ร้านค้าที่กรอกข้อมูล ตรงกับรูปภาพ: 73 ร้าน
- ร้านค้าที่กรอกข้อมูล ไม่ตรงกับรูปภาพ: 3 ร้าน

Distribution ตาม Category (จากข้อมูลที่กรอก):

Category	จำนวนร้าน
ช้อปปิ้ง	37
อาหารและเครื่องดื่ม	16
บริการต่างๆ	15
สุขภาพและความงาม	5
ท่องเที่ยว	2
บันเทิง	1

Insight เชิง Data Science

- Dataset มี class imbalance สูงมาก (≈ 96% match)
- Accuracy จะเป็น metric ที่หลอกตา (misleading)
- False Negative (ปล่อย merchant ผิดหมวด) มี cost สูงกว่าทาง business

3.4 Data Quality Issues

พบประเด็นสำคัญดังนี้:

- มี 1 ร้านค้าที่เลือกวิธีการชำระเงินไม่สอดคล้องกับภาพ
- บางร้านมีภาพที่:
    - ไม่สะท้อน category โดยตรง
    - เป็นภาพเชิงนามธรรม (โลโก้, ป้าย)
    - มีหลายบริบทในภาพเดียว

ข้อจำกัดเหล่านี้ชี้ให้เห็นว่า:

ปัญหานี้ไม่ใช่ pure image classification แต่เป็น semantic consistency problem ภายใต้ข้อมูลที่ noisy

IV. ระเบียบวิธีและแนวทางการแก้ปัญหา (Methodology)

ภาพรวม Pipeline

1. Image preprocessing (resize, normalization)
2. Text prompt engineering (category description)
3. Image–Text representation learning
4. Similarity computation
5. Decision layer (threshold / classifier)
6. Confidence scoring & logging

4.1 Problem Formulation

ปัญหา Merchant Guard ถูกกำหนดเป็น Image–Text Consistency Verification โดยมีวัตถุประสงค์เพื่อประเมินว่า:

ภาพที่ merchant อัปโหลด มีความสอดคล้องเชิงความหมาย (semantic alignment) กับ Category / Subcategory ที่ merchant เลือกหรือไม่

จากลักษณะข้อมูลจริง ปัญหานี้ ไม่ใช่ multi-class image classification แต่เป็น:

- Multimodal semantic matching
- ภายใต้ class imbalance สูง
- และมี multi-image ต่อหนึ่ง merchant

ดังนั้น methodology ต้อง:

- รองรับ semantic reasoning
- ไม่ผูกติดกับ taxonomy แบบ fixed
- ให้ confidence score สำหรับ risk-based decision

4.2 Overview of Proposed Approaches

เพื่อแก้ปัญหานี้ ได้พิจารณา 2 แนวทางหลักที่เป็น State-of-the-Art ในปัจจุบัน ได้แก่:

1. Approach ที่ 1: Vision–Language Embedding Model (CLIP-based)
2. Approach ที่ 2: Large Multimodal Models (LMMs) – Qwen2.5-VL

ทั้งสองแนวทางถูกประเมินภายใต้เกณฑ์เดียวกัน:

- ความสามารถในการเข้าใจ semantic ระหว่างภาพและข้อความ
- ความเหมาะสมกับ dataset ขนาดเล็ก (76 ร้าน)
- ความสามารถในการ deploy ใน production
- ความเสถียรและ reproducibility

4.3 Approach ที่ 1: CLIP-based Image–Text Similarity

4.3.1 Core Concept

CLIP เป็น Vision–Language Model ที่เรียนรู้ joint embedding space ระหว่างภาพและข้อความ โดย:

- Image Encoder และ Text Encoder ถูก train ให้ representation ของภาพและคำอธิบายที่ “สอดคล้องกัน” อยู่ใกล้กันใน vector space
- ใช้ cosine similarity เป็นตัววัด semantic alignment

ในบริบทนี้:

- ภาพร้านค้า ⟶ image embedding

- Category / Subcategory ⟶ text embedding
- Similarity score ⟶ ระดับความสอดคล้อง

4.3.2 Pipeline Design

1. Image Processing
    - Resize / normalize ภาพ
    - Encode แต่ละภาพเป็น embedding
2. Text Representation
    - แปลง Category / Subcategory เป็น descriptive prompt (ลด semantic sparsity ของ label สั้น ๆ)
3. Multi-image Aggregation
    - Aggregate similarity จากหลายภาพต่อร้าน (เช่น mean / max / weighted aggregation)
4. Decision Layer
    - เปรียบเทียบ similarity กับ threshold τ
    - Output: Match / Mismatch + confidence score

4.3.3 Strengths

- รองรับ open-vocabulary และ category ใหม่
- ไม่ต้อง train จาก scratch (เหมาะกับ data ขนาดเล็ก)
- Inference เร็ว และ cost ต่ำ
- Confidence score มีความหมายเชิง ranking

4.3.4 Limitations

- ไม่สามารถอธิบายเหตุผลเชิง language ได้
- Sensitive ต่อ prompt design
- ไม่เข้าใจ business logic โดยตรง (เช่น intent ของร้าน)

4.4 Approach ที่ 2: Large Multimodal Models (Qwen2.5-VL)

4.4.1 Core Concept

Large Multimodal Models (LMMs) เช่น Qwen2.5-VL สามารถ:

- เข้าใจภาพ + ข้อความพร้อมกัน
- ทำ visual reasoning และ semantic inference

- ตอบคำถามเชิงตรรกะเกี่ยวกับภาพ

ในโจทย์นี้ LMM สามารถถูกใช้ในรูปแบบ:

- Prompt-based classification
- หรือ reasoning-based verification
  (“ภาพนี้เหมาะสมกับร้านอาหารหรือไม่ เพราะเหตุใด”)

4.4.2 Pipeline Design

1. ส่งภาพ + Category description เข้าโมเดล
2. ใช้ prompt ให้โมเดลตัดสิน:
   - Yes / No
   - พร้อมเหตุผล
3. แปลง output เป็น decision และ confidence proxy

4.4.3 Strengths

- เข้าใจ context เชิงลึก
- อธิบายเหตุผลได้ (explainability สูง)
- Robust กับภาพที่มีหลาย object หรือ abstract

4.4.4 Limitations

- Inference cost สูง
- Latency สูง ไม่เหมาะกับ real-time onboarding
- Output ไม่ deterministic (temperature, prompt sensitivity)
- ยากต่อ calibration ของ confidence score
- Overkill สำหรับ dataset ขนาดเล็กและ label ง่าย

4.5 Model Selection Rationale

หลังจากเปรียบเทียบทั้งสองแนวทาง ภายใต้บริบทของข้อมูลและ business requirement ได้เลือกใช้:

Approach ที่ 1: CLIP-based Vision–Language Model

เหตุผลหลัก:

- ปัญหานี้ต้องการ semantic alignment scoring มากกว่า reasoning แบบ open-ended
- Dataset มีขนาดเล็ก ⟶ ไม่เหมาะกับ LMM inference-heavy
- ต้องการ deploy ได้จริงใน production (low latency, low cost)
- CLIP ให้ confidence score ที่นำไป threshold และ monitor ได้ง่าย

LMM (Qwen2.5-VL) ถูกพิจารณาเป็น:

- Baseline เชิง qualitative
- หรือ future enhancement สำหรับ hard cases / human-in-the-loop

4.6 Trade-offs Summary

Dimension	CLIP	Qwen2.5-VL
Semantic Matching	ดีมาก	ดีมาก
Explainability	ต่ำ	สูง
Inference Cost	ต่ำ	สูง
Scalability	สูง	ต่ำ
Production Readiness	สูง	ปานกลาง
Suitability	สูง	ต่ำ

V. การพัฒนาและออกแบบโมเดล (Model Development)

5.1 Model Architecture Overview

ระบบ Merchant Guard ใช้ Vision–Language Model แบบ Multilingual CLIP (mCLIP) เป็นแกนหลัก โดยเลือกสถาปัตยกรรม

xlm-roberta-large-ViT-H-14 ซึ่งประกอบด้วย:

- Image Encoder: Vision Transformer (ViT-H-14)
- Text Encoder: Multilingual Transformer (XLM-RoBERTa)
- Shared Embedding Space สำหรับวัด semantic similarity ระหว่างภาพและข้อความ

การเลือกโมเดลนี้มีเป้าหมายเพื่อ:

- รองรับข้อความภาษาไทยและอังกฤษ
- ลด dependency ต่อ data labeled จำนวนมาก
- ทำ semantic matching แบบ open-vocabulary

5.2 Text Representation Strategy

แทนที่จะ encode เพียง Category ระดับบน ระบบใช้ Subcategory ทั้งหมดเป็น text anchor โดย:

- Flatten subcategories ทั้งหมดจาก CATEGORY_MAP
- Encode subcategory ทุกตัวล่วงหน้าเป็น text embedding
- Map กลับไปยัง parent category ภายหลัง

แนวคิดนี้ช่วย:

- เพิ่ม semantic resolution ของ text side
- ลด ambiguity ของ category ที่กว้างเกินไป (เช่น “ช้อปปิ้ง”)

5.3 Image Representation & Multi-image Aggregation

เนื่องจาก 1 ร้านค้ามีหลายภาพ ระบบจึง:

- Encode ภาพหลายใบ (สูงสุด 4 ภาพต่อร้าน)
- Normalize embedding ทุกภาพ
- Aggregate ด้วย mean pooling เพื่อสร้าง shop-level representation

การ aggregate ระดับร้านแทนภาพเดี่ยว:

- ลด noise จากภาพที่ไม่ represent ธุรกิจจริง
- สอดคล้องกับ unit of decision ในเชิง business (merchant-level)

5.4 Similarity Scoring & Category Decision

ขั้นตอนการตัดสินใจประกอบด้วย:

1. คำนวณ similarity ระหว่าง shop embedding กับ subcategory embeddings
2. เลือก score สูงสุดของแต่ละ parent category
3. Normalize score เพื่อให้เป็น probability distribution
4. เลือก category ที่มี score สูงสุดเป็นผลลัพธ์

พร้อมทั้ง:

- เก็บ confidence score สำหรับ downstream decision (thresholding / human review)

5.5 OCR-assisted Semantic Boosting

เพื่อเสริม visual signal ระบบผสาน OCR-based textual cue โดย:

- ใช้ EasyOCR (รองรับ TH + EN)
- Extract text จากภาพร้าน
- ตรวจจับ keyword เชิง domain
- เพิ่ม score ให้ category ที่มี keyword match

แนวคิดนี้ช่วย:

- แก้กรณีภาพ generic แต่มีข้อความบ่งชี้ชัด (เช่น ป้ายร้าน)
- ลด false negative ใน category ที่พึ่งพา text สูง (อาหาร, บริการ)

อย่างไรก็ตาม OCR ถูกใช้เป็น supporting signal ไม่ใช่ primary decision maker เพื่อลด bias จาก text noise

5.6 Output Design

ผลลัพธ์สุดท้ายของระบบต่อร้านค้าประกอบด้วย:

- Predicted Category

- Predicted Subcategory
- Confidence Score
- Raw category score distribution
- OCR text log (สำหรับ error analysis)

การออกแบบนี้รองรับ:

- Explainability
- Auditability
- Human-in-the-loop workflow

VI. ตัวชี้วัดและเกณฑ์การประเมินผล (Evaluation Metrics)

6.1 Metric Selection Rationale

ปัญหา Merchant Guard เป็น Trust & Safety problem ภายใต้ class imbalance สูง

โดยมีความเสี่ยงหลักคือ:

ปล่อยร้านค้าที่เลือก category ผิดให้ผ่านระบบ (False Negative)

ดังนั้น metric ที่เหมาะสมต้อง:

- ให้ความสำคัญกับ Recall มากกว่า Precision
- สะท้อน business risk มากกว่า accuracy เชิงสถิติ

6.2 Why F2-score?

เลือกใช้ **F2-score** เป็น metric หลัก เนื่องจาก:

$$F_2 = \frac{(1 + 2^2) \cdot Precision \cdot Recall}{(2^2 \cdot Precision) + Recall}$$

โดย F2-score:

- ให้น้ำหนักกับ Recall มากกว่า Precision (2:1)
- เหมาะกับ use case ที่:
    - False Negative มีต้นทุนสูง
    - ยอมรับ False Positive ได้ในระดับหนึ่ง (ส่ง human review)

ในบริบทนี้:

- การพลาดร้านที่ผิดหมวด = risk ต่อ ecosystem
- การ flag ร้านถูกผิดบ้าง = ต้นทุนต่ำกว่า

6.3 Metrics Used in Evaluation

ระบบรายงานผลด้วย metrics หลักดังนี้:

- **Macro F2-score**

  วัด performance แบบให้ทุก category มีน้ำหนักเท่ากัน
- **Weighted F2-score**

  สะท้อน performance ตาม distribution จริง
- **Confusion Matrix (Normalized)**

  วิเคราะห์ error pattern ระหว่าง category
- **Confidence Score Distribution**

  ประเมิน separability ของ decision boundary

Accuracy และ F1-score ถูกใช้เป็น metrics รองเพื่อ reference เท่านั้น

6.4 Category-level Performance Analysis

มีการรายงาน:

- Precision / Recall / F2-score ราย category
- วิเคราะห์ category ที่:
  - Recall ต่ำ ⟶ เสี่ยง false negative
  - Confidence กระจุกตัวต่ำ ⟶ semantic ambiguity สูง

ช่วยชี้แนวทาง:

- ปรับ threshold แบบ category-specific
- เลือก category ที่ควร human review เป็นพิเศษ

6.5 Consistency-level Evaluation (Business View)

นอกจาก multi-class classification ยังมีการประเมินในมุม Consistency Checking:

- เปรียบเทียบ:
  - Original Category (merchant input)
  - True Category
  - Predicted Category

และวัดผลด้วย:

- Accuracy
- Weighted F2-score (Consistency)

การประเมินระดับนี้สะท้อน business objective โดยตรง มากกว่าการดู category prediction เพียงอย่างเดียว

สรุปเชิงเทคนิค

- Model development ถูกออกแบบให้ robust ต่อ data น้อย + noise สูง
- F2-score ถูกเลือกอย่างมีเหตุผลตาม risk profile ของ Trust & Safety
- ระบบให้ทั้ง prediction, confidence และ signal สำหรับ human-in-the-loop
- พร้อมต่อยอดสู่ production โดยไม่ต้อง retrain โมเดลหลัก

VII. การวิเคราะห์และตีความผลลัพธ์ (Results Interpretation)

7.1 Overall Model Performance

จากการประเมินบนร้านค้าทั้งหมด 76 ร้าน ระบบให้ผลลัพธ์โดยรวมดังนี้:

- **Accuracy = 65.79%**
- **Macro F2-score = 0.409**
- **Weighted F2-score = 0.642**

แม้ accuracy จะอยู่ในระดับปานกลาง แต่ผลลัพธ์นี้ต้องตีความภายใต้บริบทที่ว่า:

- Dataset มี class imbalance สูง
- Category “ช้อปปิ้ง” ครองสัดส่วนข้อมูลมากที่สุด
- เป้าหมายหลักคือ ลด false negative (ร้านผิดหมวดที่หลุดรอด) ไม่ใช่ maximize accuracy

Weighted F2-score ที่สูงกว่า Macro F2-score อย่างชัดเจน สะท้อนว่า:

- โมเดลทำงานได้ดีใน category ที่มีข้อมูลมาก
- แต่ยังมีความท้าทายใน category ที่มี sample น้อยและ semantic overlap สูง

7.2 Category-level Behavior Analysis

การกระจายของ confidence score แสดง pattern ที่สอดคล้องกับลักษณะข้อมูลจริง:

- ช้อปปิ้ง
    - ค่าเฉลี่ย confidence สูงที่สุด (0.808)
    - แต่มี variance สูง ⟶ บ่งชี้ semantic breadth ของ category
- อาหารและเครื่องดื่ม / สุขภาพและความงาม
    - confidence ค่อนข้างสูงและกระจายแคบ
    - แสดงว่า visual cue ชัด (อาหาร, คลินิก, ร้านเสริมสวย)
- บริการต่างๆ
    - mean confidence ต่ำสุด (0.666)
    - std สูง ⟶ เป็น category ที่ ambiguity สูงสุด

Insight สำคัญ:

Category ที่อธิบายธุรกิจผ่าน “การกระทำ” มากกว่า “วัตถุ” จะยากสำหรับ vision-based model

7.3 Error Pattern & Confusion Analysis

Top confused pairs ให้ insight เชิงโครงสร้างของปัญหา:

1. บริการต่างๆ ⟶ ช้อปปิ้ง (8 cases)
    - ภาพเน้นอุปกรณ์หรือสินค้า มากกว่าบริการ
    - CLIP เอนเอียงไปหา object-centric category
2. อาหารและเครื่องดื่ม ⟶ ช้อปปิ้ง (5 cases)
    - ภาพเป็น packaged food หรือสินค้าแห้ง
    - Visual similarity สูงกับ retail environment
3. ช้อปปิ้ง ⟶ สุขภาพและความงาม (4 cases)
    - ร้านขายเครื่องสำอาง vs คลินิกความงาม
    - Semantic overlap สูงในระดับ subcategory

ข้อสรุปเชิงเทคนิค:

Error ส่วนใหญ่ไม่ได้เกิดจาก “โมเดลไม่ดี”

แต่เกิดจาก taxonomy ambiguity และ visual overlap ระหว่าง business types

7.4 Consistency Checking Perspective (Business-Oriented)

เมื่อประเมินในมุม Consistency Checking (ตรง / ไม่ตรงกับที่ merchant กรอก):

- **Weighted F2-score = 0.6803**
- **Accuracy = 65.79%**

ผลลัพธ์นี้สะท้อนว่า:

- โมเดลสามารถจับ inconsistency ได้ในระดับที่ใช้งานได้จริง
- แต่ยังไม่ควรถูกใช้เป็น hard gate แบบ auto-reject

อย่างไรก็ตาม โมเดลมีคุณค่าอย่างมากในบทบาท:

- Early risk signal
- Pre-screening layer ก่อน human review

VIII. ข้อจำกัดของระบบและการทดลอง (Limitations)

แม้ระบบ Merchant Guard จะสามารถตรวจจับความไม่สอดคล้องระหว่างภาพและ Category ได้ในระดับที่ใช้งานได้จริง แต่ยังมีข้อจำกัดสำคัญในหลายมิติ ซึ่งต้องพิจารณาอย่างรอบคอบก่อนนำไปใช้ใน production เต็มรูปแบบ

8.1 Dataset Size & Class Imbalance

ข้อจำกัดเชิงโครงสร้างที่สำคัญที่สุดคือ ขนาดข้อมูลที่เล็กมาก:

- ร้านค้าทั้งหมดเพียง 76 ร้าน
- Category distribution ไม่สมดุลอย่างรุนแรง
- บาง category มีข้อมูลน้อยมาก (เช่น บันเทิง, ท่องเที่ยว)

ผลกระทบ:

- Macro F2-score ต่ำ เนื่องจาก category เล็กมี variance สูง
- การประเมิน performance ต่อ category มีความไม่เสถียร
- Threshold ที่ได้อาจ overfit กับ distribution ชุดนี้

สรุป:

โมเดลยังไม่สามารถอ้างอิง performance เชิงสถิติในระดับ population ได้

8.2 Ambiguity of Business Taxonomy

Category และ Subcategory ถูกออกแบบจากมุม business ไม่ใช่จาก visual separability

ตัวอย่าง:

- “ช้อปปิ้ง” vs “บริการต่างๆ”
- “ร้านขายเครื่องสำอาง” vs “คลินิกความงาม”

ข้อจำกัดนี้ทำให้:

- Visual overlap สูงโดยธรรมชาติ
- Error หลายกรณีเป็น semantic disagreement มากกว่า model mistake
- Confusion matrix สะท้อนโครงสร้าง taxonomy มากกว่าความสามารถโมเดล

สรุป:

ปัญหานี้มี upper bound ของ performance ที่ถูกจำกัดโดยนิยาม category เอง

8.3 Visual-Centric Bias ของ CLIP

CLIP เป็นโมเดลที่:

- ให้ความสำคัญกับ object และ scene ที่มองเห็นได้
- ไม่เข้าใจ “intent” หรือ “service flow”

ผลกระทบ:

- ร้านบริการที่ใช้ภาพอุปกรณ์ ⟶ ถูกตีความเป็นร้านค้า
- ร้านอาหารที่ขายสินค้าแพ็ก ⟶ ถูกตีความเป็นช้อปปิ้ง

ข้อจำกัดนี้เป็น model inductive bias ไม่ใช่ bug

8.4 Limited Use of Contextual Information

ระบบปัจจุบันใช้:

- ภาพ
- Category / Subcategory
- OCR text

แต่ ไม่ได้ใช้ข้อมูลบริบทอื่น เช่น:

- ชื่อร้าน
- คำอธิบายร้าน
- ประเภทธุรกรรม
- ประวัติพฤติกรรม merchant

ผลกระทบ:

- การตัดสินใจอิง visual cue เป็นหลัก
- ไม่สามารถ resolve ambiguity ใน hard cases ได้

สรุป:

โมเดลทำงานในบริบทข้อมูลที่จำกัดกว่าความเป็นจริงของธุรกิจ

8.5 OCR Dependency & Noise

แม้ OCR จะช่วยเพิ่ม recall แต่มีข้อจำกัดสำคัญ:

- คุณภาพ OCR แปรผันตาม:
    - ความคมชัดของภาพ
    - ภาษา / ฟอนต์
    - มุมกล้อง
- Keyword-based boosting เป็น heuristic
- เสี่ยงต่อ false boost จาก text ที่ไม่เกี่ยวกับ business

ดังนั้น OCR:

- เป็น signal เสริม ไม่ใช่ ground truth
- ต้องควบคุมน้ำหนักอย่างระมัดระวัง

8.6 Fixed Heuristics & Manual Thresholding

ระบบใช้:

- Fixed OCR boost weight
- Aggregation แบบ mean
- Threshold ที่เลือกจาก dataset เดียว

ข้อจำกัด:

- ไม่ adaptive ต่อ category
- ไม่เรียนรู้จาก feedback
- อาจไม่ generalize ไปยัง data ใหม่

สรุป:

Decision logic ยังเป็น rule-based มากกว่าที่ควรจะเป็นใน production ระยะยาว

8.7 Lack of Temporal & Continual Learning

ระบบปัจจุบัน:

- เป็น static model
- ไม่เรียนรู้จาก merchant ใหม่
- ไม่ปรับตาม trend หรือ seasonality

ผลกระทบ:

- Performance อาจ degrade เมื่อ distribution เปลี่ยน
- ไม่สามารถ adapt ต่อ merchant behavior ใหม่

8.8 Explainability ยังไม่เพียงพอสำหรับบาง use case

แม้มี confidence score และ OCR log:

- ระบบยังไม่สามารถอธิบายเชิง causal ได้
- ไม่สามารถตอบได้ชัดเจนว่า “ผิดเพราะอะไร” ในทุกกรณี

สำหรับ Trust & Safety บาง scenario:

- Human reviewer อาจต้องการ explanation ที่ละเอียดกว่านี้

สรุปเชิง Limitations

ข้อจำกัดส่วนใหญ่ของระบบ:

- ไม่ได้เกิดจาก implementation
- แต่เกิดจาก data regime, taxonomy design และ nature ของ visual reasoning

สิ่งนี้สะท้อนว่า:

โมเดลนี้เหมาะกับบทบาท decision support + risk screening
มากกว่า fully autonomous decision maker

IX. ผลกระทบเชิงธุรกิจและการใช้งานจริง (Business Impact)

9.1 Operational Impact

หากนำระบบนี้ไปใช้ใน production จะสามารถ:

- ลด workload ของทีม manual review
- Flag ร้านค้าที่มีความเสี่ยงสูงโดยอัตโนมัติ
- เร่ง onboarding สำหรับร้านที่ confidence สูง

โดยเฉพาะเมื่อใช้ร่วมกับ **confidence thresholding**:

Confidence Range	Action
สูงมาก (>0.85)	Auto-approve
ปานกลาง (0.6–0.85)	Human review
ต่ำ (<0.6)	Risk flag

9.2 Risk Management Perspective

การเลือกใช้ **F2-score** สอดคล้องกับ risk profile ของธุรกิจ:

- False Negative

  ⟶ ร้านผิดหมวดหลุดเข้า ecosystem

  ⟶ กระทบ trust และ compliance
- False Positive

  ⟶ ร้านดีถูกตรวจเพิ่ม

  ⟶ ต้นทุนต่ำกว่าและควบคุมได้

ดังนั้นโมเดลถูกออกแบบให้:
“ยอมเหนื่อยเพิ่มเล็กน้อย เพื่อไม่ให้ความเสี่ยงหลุดรอด”

9.3 Strategic Value

แม้ performance ยังไม่สมบูรณ์แบบ ระบบนี้ให้:

- Consistent decision framework
- Audit trail ผ่าน confidence + score distribution
- Foundation สำหรับ Trust & Safety automation ระยะยาว

ที่สำคัญ:
โมเดลนี้ scale ได้โดยไม่เพิ่ม human cost ซึ่ง manual review ทำไม่ได้

X. แนวทางการพัฒนาและต่อยอดในอนาคต (Future Improvements)

เพื่อยกระดับระบบ Merchant Guard จาก prototype สำหรับ decision support ไปสู่ production-grade Trust & Safety system สามารถพัฒนาเพิ่มเติมได้ในหลายมิติ ดังนี้

10.1 Data Expansion & Label Quality Improvement

แนวทาง

- เพิ่มจำนวนร้านค้าอย่างมีระบบ โดยเฉพาะ category ที่มีข้อมูลน้อย
- เก็บ data จากหลายช่วงเวลาและหลายพื้นที่
- แยก label ระหว่าง:
    - “ผิดชัดเจน”
    - “ก้ำกึ่ง / ambiguous”
    - “ถูกต้องชัดเจน”

ประโยชน์

- ลด variance ของ metric ระดับ category
- ทำให้ threshold calibration มีเสถียรภาพ
- รองรับ model selection เชิงสถิติได้จริง

10.2 Category-specific Thresholding

แทนการใช้ threshold เดียวสำหรับทุก category:

- เรียนรู้ threshold แยกตาม category
- ใช้ ROC / Precision–Recall curve เฉพาะกลุ่ม

ตัวอย่าง:

- อาหารและเครื่องดื่ม ⟶ threshold ต่ำ (visual cue ชัด)
- บริการต่างๆ ⟶ threshold สูง (ambiguity สูง)

ผลลัพธ์

- ลด false negative ใน category เสี่ยง
- เพิ่ม business-aligned decision making

10.3 Multi-image Attention & Weighting

ปัจจุบันใช้ mean pooling แบบเท่ากันทุกภาพ

สามารถพัฒนาเป็น:

- Image quality scoring
- Attention-based aggregation
- Weight ภาพที่มี OCR / object confidence สูงมากกว่า

Benefit

- ลดผลกระทบจากภาพ noise
- เพิ่ม robustness ต่อร้านที่อัปโหลดภาพหลากหลาย

10.4 Fine-tuning Vision–Language Model (Domain Adaptation)

แม้ CLIP จะเป็น zero-shot ที่ดี แต่สามารถ fine-tune ด้วย:

- Merchant domain image–text pairs
- Hard negative samples (category ที่คล้ายกัน)

Expected Gain

- ลด confusion ระหว่าง:
    - ช้อปปิ้ง vs บริการ
    - สุขภาพและความงาม vs ร้านขายสินค้า

10.5 Integrating Large Multimodal Models (Hybrid System)

LMMs เช่น Qwen2.5-VL สามารถถูกนำมาใช้ใน:

- Second-stage validation
- Hard case resolution
- Human reviewer assistance

Workflow ตัวอย่าง:

1. CLIP ⟶ fast screening
2. LMM ⟶ reasoning สำหรับ low-confidence cases

ข้อดี

- เพิ่ม explainability
- ใช้ resource อย่างคุ้มค่า

10.6 Rich Context Integration

เพิ่มข้อมูลบริบทอื่นเข้ามาใน decision:

- ชื่อร้าน

- คำอธิบายร้าน
- ประเภทธุรกรรม
- Merchant metadata

สามารถทำเป็น:

- Late fusion
- Ensemble decision

ผลลัพธ์

- ลด reliance ต่อภาพเพียงอย่างเดียว
- แก้ ambiguity ที่ visual model แก้ไม่ได้

10.7 Continual Learning & Feedback Loop

ออกแบบระบบให้:

- เรียนรู้จากผล human review
- Update threshold หรือ model periodically
- Detect data drift อัตโนมัติ

Benefit

- โมเดลปรับตัวตาม merchant behavior
- ลด performance degradation ระยะยาว

10.8 Explainability & Reviewer Tooling

พัฒนา dashboard สำหรับ reviewer:

- Highlight image region ที่มีผลต่อ decision
- แสดง top competing categories
- แสดง OCR evidence

ผลกระทบ

- ลดเวลาการ review
- เพิ่ม trust ใน AI system
- ลด friction ระหว่าง human กับ model

10.9 Advanced Risk Scoring Framework

ขยายจาก binary decision ⟶ risk score:

- Combine:
    - CLIP similarity

    - OCR confidence
    - Historical merchant behavior
- ใช้ Bayesian / scoring model

Use Case

- Progressive enforcement
- Tiered onboarding

10.10 Governance, Monitoring & Compliance

ในระดับองค์กร ควรมี:

- Performance monitoring per category
- Bias audit (small category / local business)
- Model versioning & rollback

เหตุผล

- Trust & Safety system ต้อง audit ได้
- ลด regulatory และ reputational risk

สรุป

Future improvements ทั้งหมดสะท้อนว่า:

Merchant Guard ไม่ควรถูกมองเป็น “โมเดลเดียว” แต่เป็น AI system สำหรับ risk management

การพัฒนาในทิศทางนี้จะ:

- เพิ่ม automation อย่างปลอดภัย
- ลดต้นทุนระยะยาว
- สร้าง trust ใน ecosystem อย่างยั่งยืน

บทสรุป (Conclusion)

รายงานฉบับนี้นำเสนอการออกแบบและพัฒนา Merchant Guard ซึ่งเป็นระบบอัตโนมัติสำหรับตรวจสอบความสอดคล้องระหว่าง ภาพที่ร้านค้าอัปโหลด กับ หมวดหมู่ที่ร้านค้าเลือกขณะลงทะเบียน โดยมีเป้าหมายหลักเพื่อเสริมสร้างความน่าเชื่อถือ ความปลอดภัย และคุณภาพของ merchant ecosystem

จากการศึกษางานวิจัยและแนวทาง State-of-the-Art พบว่า Vision–Language Models โดยเฉพาะแนวคิด Image–Text Consistency Checking เป็นแนวทางที่เหมาะสมที่สุดสำหรับปัญหานี้ รายงานจึงได้นำเสนอ 2 แนวทางหลัก ได้แก่

1. การใช้ CLIP ในรูปแบบ zero-shot classification

2. การใช้ Large Multimodal Models (LMMs) เช่น Qwen2.5-VL

โดยเลือก CLIP เป็นโมเดลหลักสำหรับการพัฒนา prototype เนื่องจากมีความสมดุลระหว่างประสิทธิภาพ ความเร็ว และต้นทุนการใช้งาน ทำให้เหมาะกับการนำไปใช้งานจริงในระบบที่ต้องรองรับ merchant จำนวนมาก

ผลการทดลองบนข้อมูลร้านค้าจำนวน 76 ร้าน (386 รูปภาพ) แสดงให้เห็นว่าระบบสามารถตรวจจับความไม่สอดคล้องระหว่างภาพและหมวดหมู่ได้ในระดับที่น่าพอใจ โดยมี Accuracy 65.79% และ Weighted F2-Score 0.6803 อย่างไรก็ตาม การวิเคราะห์เชิงลึกพบว่าโมเดลยังมีข้อจำกัดในหมวดหมู่ที่มีความคลุมเครือทางภาพสูง เช่น “บริการต่างๆ” และมีอคติไปยังหมวด “ช้อปปิ้ง” ซึ่งเป็นหมวดที่มีข้อมูลมากที่สุด
จาก Error Analysis และ Performance Analysis ชี้ให้เห็นว่า ปัญหานี้ไม่สามารถแก้ได้ด้วยโมเดลภาพเพียงอย่างเดียว แต่ต้องอาศัย บริบทเพิ่มเติม, threshold ที่แตกต่างตามหมวดหมู่, และ human-in-the-loop เพื่อให้เกิดการตัดสินใจที่สอดคล้องกับบริบทธุรกิจจริง

โดยสรุป ระบบ Merchant Guard ในรูปแบบ prototype นี้พิสูจน์ให้เห็นถึงความเป็นไปได้ของการใช้ AI เพื่อสนับสนุนกระบวนการตรวจสอบร้านค้าอย่างมีประสิทธิภาพ และสามารถพัฒนาต่อยอดไปสู่ระบบระดับ production ได้ผ่านการปรับปรุงด้านข้อมูล โมเดล และ governance ในอนาคต ทั้งนี้ ระบบดังกล่าวควรถูกมองว่าเป็น เครื่องมือช่วยตัดสินใจด้าน Trust & Safety มากกว่าการทดแทนมนุษย์โดยสมบูรณ์ เพื่อให้เกิดความสมดุลระหว่าง automation ความแม่นยำ และความเป็นธรรมใน ecosystem